

Note d'analyse

1. Le dataset

Le *German Credit Dataset* (Hofmann, 1994), rassemble 1 000 dossiers de demande de crédit instruits par une banque régionale du sud de la République fédérale d'Allemagne entre 1973 et 1975. Chaque dossier est décrit par 20 variables couvrant trois registres : le profil **socio-économique** de l'emprunteur, les **caractéristiques du prêt** sollicité et l'**historique de crédit** antérieur. La variable cible `class` est binaire et encode l'évaluation du dossier par la banque : `good` (700 observations, 70 %) ou `bad` (300 observations, 30 %).

Le dataset est mobilisé en équité algorithmique car il contient plusieurs variables socialement chargées (sexe, âge, travailleur étranger) pertinentes au regard du cadre réglementaire européen (*AI Act*, Annexe III : *credit scoring* = système à haut risque). Quatre limites épistémiques bornent ce que l'audit peut légitimement conclure :

(a) La cible est un verdict, pas un fait

La variable `class` ne dit pas « le client a remboursé », elle dit « la banque a jugé le client `good` ou `bad` ». Les deux énoncés n'ont pas le même statut épistémique.

Un client étiqueté `bad` peut correspondre à un défaut total, un retard prolongé, une restructuration acceptée ou un dossier jugé problématique selon des critères que Hofmann ne documente pas. La granularité factuelle — nombre de mois de retard, part du capital remboursée, perte effective — est écrasée par la binarisation. Le vocabulaire `good/bad` lui-même reste évaluatif et non descriptif.

Jacobs & Wallach (2021) ainsi que Friedler et al. (2016) qualifient ce phénomène de *construct invalidity* : le modèle apprend à prédire un proxy d'un phénomène inobservable sans possibilité de mesurer la fidélité du proxy.

En conséquence, tout modèle entraîné sur ces données apprend essentiellement à reproduire le verdict de la banque, et non à prédire un risque de défaut objectivement mesuré.

(b) Biais de sélection

Les 1 000 observations sont les dossiers que la banque a instruits jusqu'à l'octroi, soit $D = 1$. Le modèle estime alors $P(Y | X, D = 1)$, et non $P(Y | X)$. Les métriques fairness ne mesurent donc qu'une équité *intra-filtre*, jamais la discrimination éventuelle au seuil d'accès au crédit. La politique de prêt complète peut être massivement inéquitable tout en paraissant équitable sur le sous-ensemble observé.

(c) Les catégories protégées sont construites, pas observées

La variable `personal_status_sex` semble distinguer clairement hommes et femmes, mais cette interprétation est incorrecte.

Lors de la construction originale du dataset, W. M. Häußler a regroupé certaines combinaisons «sexe × statut matrimonial» jugées équivalentes en termes de risque de crédit. Une même modalité regroupe ainsi des hommes célibataires et des femmes non célibataires (mariées, divorcées ou séparées).

Les libellés textuels ajoutés ultérieurement (*male single*, *female div/dep/mar*, etc.) donnent à tort l'impression de catégories parfaitement distinctes. Comme l'a montré Ulrike Grömping (2019) en reconstruisant le codebook original, le sexe ne peut donc pas être récupéré de manière fiable pour tous les individus.

Comme indiqué dans la documentation officielle du dataset South German Credit Dataset (UCI Repository), la variable `personal_status_sex` contient une information combinée sur le sexe et le statut matrimonial, et «sex cannot be recovered from the variable, because male singles and female non-singles are coded with the same code».

(d) Biais historique

Les données reflètent un état du monde façonné par des inégalités structurelles passées. Les variables prédictives en héritent, indépendamment de la qualité de leur mesure. Là où (a) parle d'un verdict subjectif, le biais historique dit qu'un verdict objectif aurait été tout aussi inégal (Suresh & Gutttag 2019).

Ces quatre limites changent la manière dont les résultats quantitatifs de §2 doivent être lus. Un énoncé du type « le modèle est équitable selon l'âge avec $|\Delta_{EOPp}| < 0,05$ » signifie, plus rigoureusement : « le modèle reproduit le verdict d'une banque sud-allemande de 1973–1975 avec un écart de TPR inférieur à 5 points entre la fraction `age < 25` selon la convention Statlog et son complémentaire, sur le sous-ensemble des demandeurs acceptés. » La transposition à toute politique de scoring contemporaine n'est pas garantie.

2. Audit et borne d'inférence

L'audit porte sur une régression logistique sans régularisation, retenue comme **baseline** pour la transparence de ses coefficients en log-odds, standard du *credit scoring*.

(a) Du coût à la décision

Une décision de crédit n'est pas neutre. Accorder à tort un prêt à un client défaillant entraîne une perte sèche du capital, tandis que refuser un bon client ne produit qu'une perte d'opportunité commerciale partiellement récupérable.

Hofmann formalise cette asymétrie en attribuant à un faux positif un coût cinq fois supérieur à celui d'un faux négatif. La règle de décision optimale devient alors le seuil $\tau^* = 5/6 \approx 0,833$, bien plus exigeant que le seuil par défaut $\tau = 0,5$.

(b) Quatre métriques, un choix

L'audit distingue les **jeunes** (moins de 25 ans) des **adultes** — seule binarisation autorisant une partition non ambiguë. À ce seuil, le modèle viole trois métriques de fairness sur quatre : *Demographic Parity* avec $\Delta = -0,266$ *Equal Opportunity* avec $\Delta = -0,251$, et *Equalized Odds*, dominée par sa composante TPR. Seule *Predictive Parity* reste satisfaite avec $\Delta = +0,023$.

Nous retenons **Equal Opportunity** comme cible de mitigation. Les trois autres métriques sont écartées comme cibles directes. *Demographic Parity* est rejetée car son égalisation forcerait à accorder du crédit à des profils défaillants, alimentant la boucle de rétroaction décrite par Ensign et al. (2018). *Equalized Odds*, dominée par TPR, devient redondante avec *EOpp*, sa composante FPR est néanmoins conservée comme garde-fou.

(c) Mitigation et arbitrage

L'*Equal Opportunity* mesure l'écart de TPR entre groupes. On ambitionne de le corriger en augmentant le TPR des jeunes — et non en abaissant celui des adultes, voie qui réduirait l'écart sans bénéfice opérationnel pour les jeunes. Or chez ces derniers, les distributions de scores des bons ($Y = 1$) et des mauvais payeurs ($Y = 0$) se chevauchent fortement autour du seuil τ^* : dans cette zone indiscernable, tout abaissement du seuil pour gagner des vrais positifs accepte mécaniquement, dans des proportions comparables, des faux positifs.

La géométrie des scores impose donc un **compromis entre la métrique de fairness et le coût institutionnel bancaire**.

À ce chevauchement intra-groupe s'ajoute un décalage inter-groupes : les scores des jeunes sont globalement plus bas (médiane $\approx 0,69$ contre $\approx 0,84$ chez les adultes), de sorte qu'un seuil unique leur impose une exigence statistique implicitement plus stricte. Cette double asymétrie a motivé l'exploration de Hardt et al. (2016), qui apprend des seuils de décision différenciés par groupe sous contrainte explicite de coût 5 :1. Les résultats valident la promesse : $|\Delta_{EOpp}|$ ramené à 0,044 pour un surcoût limité à +4 %. Mais la méthode procède par randomisation : deux profils identiques peuvent recevoir des décisions opposées. Hardt résout le compromis fairness/coût au prix d'une violation de l'**équité individuelle**, sacrifiée au bénéfice de l'équité collective.

Nous retenons alors le reweighting (Kamiran & Calders 2012), qui surpondère en amont les jeunes solvables pendant l'apprentissage. Il ramène $|\Delta_{EOpp}|$ à 0,016 pour un surcoût de +15 %, en préservant la cohérence individuelle des décisions. L'amélioration provient toutefois d'une translation globale des scores des jeunes plutôt que d'un gain réel de séparabilité.

(d) Pourquoi cette zone de chevauchement ? — analyse informationnelle

Deux origines sont possibles — une limite du modèle ou une limite de l'information disponible — et sont testées successivement.

L'hypothèse d'une limite du modèle est examinée en premier. La régression logistique impose une frontière linéaire ; un classifieur non linéaire, bien plus expressif, devrait pouvoir séparer ces profils si la difficulté tenait à la forme de la frontière. Or un XGBoost produit des scores quasi identiques à ceux de la régression logistique sur les individus ambigus : les mêmes jeunes restent indiscernables dans les deux modèles. Le chevauchement n'est donc pas un artefact de la régression mais une propriété des variables elles-mêmes.

L'analyse passe alors au niveau local, par l'intermédiaire de SHAP, qui décompose le score de chaque individu en contributions attribuées aux différentes variables. Pour observer comment ces contributions évoluent quand on s'approche de la zone d'ambiguïté, nous définissons chez les jeunes quatre sous-populations en croisant la vraie classe (good / bad) avec la position dans l'espace des scores (zone fiable, zone d'overlap autour de τ^*). Nous comparons ces populations à deux niveaux complémentaires.

Au niveau agrégé, le SHAP moyen par variable est comparé entre les quatre populations. Dans les zones fiables, les variables importantes contribuent dans des directions opposées selon la classe : ce qui pousse un good vers le haut pousse un bad vers le bas. Dans la zone d'overlap, cette opposition s'efface — les contributions des deux classes deviennent proches en signe comme en amplitude.

Au niveau individuel, la reconstruction du score variable par variable confirme que le signal n'est pas absent. Chaque individu de l'overlap reçoit bien des contributions positives et négatives d'amplitude significative ; mais leur somme nette ne dégage plus de direction claire. **Le signal existe, c'est sa dominance qui s'effrite.**

Ce constat conduit à introduire une distinction que les métriques globales ne capturent pas : la **contribution** d'une variable au score (son poids dans le calcul) et son **pouvoir discriminant** (sa capacité à séparer good de bad). Une variable peut continuer à influencer fortement les scores sans pour autant aider à distinguer les classes. Dans la zone d'overlap, ces deux dimensions se dissocient nettement : les variables y restent actives, mais leur capacité séparatrice s'effondre localement.

Ce constat conduit à introduire une distinction que les métriques globales ne capturent pas : la **contribution** d'une variable au score (son poids dans le calcul) et son **pouvoir discriminant** (sa capacité à séparer good de bad). Une variable peut continuer à influencer fortement les scores sans pour autant aider à distinguer les classes. Dans la zone d'overlap, ces deux dimensions se dissocient nettement : les variables y restent actives, mais leur capacité séparatrice s'effondre localement.

La conclusion n'est pas qu'il n'existe pas de solution, mais que la solution n'est plus algorithmique. Trois voies restent ouvertes, déplacées vers le niveau opérationnel : enrichir l'information disponible (avec un pouvoir plus discriminant au niveau de l'overlap), router la zone d'overlap vers une décision humaine (Article 14 de l'*AI Act*), ou substituer à la binarité accord/refus une contractualisation graduée (montants ou garanties adaptés au niveau d'incertitude). L'audit ne dit pas « comment le modèle doit décider », il dit « où le modèle ne doit pas décider seul ».

(e) Robustesse au déplacement démographique

La promesse fairness du reweighting est conditionnelle à la stabilité de $P(A)$ entre apprentissage et déploiement. En faisant varier la proportion de jeunes de 5 % à 40 %, on observe que le modèle naturel reste stable en coût (≈ 165) mais conserve son inéquité ($|\Delta_{EOpp}| \approx 0,25$), tandis que le reweighting maintient sa promesse fairness ($|\Delta_{EOpp}| < 0,10$) au prix d'une dérive du coût bancaire (+12,5 % entre référence et shift extrême). **Le reweighting déplace l'incertitude vers l'opérationnel, il ne la supprime pas.** Ce résultat est cohérent avec l'analyse SHAP : tous deux pointent vers un plafond de la mitigation algorithmique — l'une au niveau des variables (la séparabilité manque), l'autre au niveau du déploiement (le coût dérive sous shift).